

我会按“先搭框架、再讲公式、再解释它们之间关系”的方式来讲，重点放在真正常用的核心公式，而不是把整本教材的公式全堆出来。你要是更想看某一块，比如线性回归、神经网络、概率图模型，后面我也可以单独继续展开。

Thought for 31s

下面这份可以当作“机器学习公式总览”。我不会把所有流派的公式机械罗列，而是按机器学习真正的主线来讲：**模型怎么表示、损失怎么定义、参数怎么更新、效果怎么评估**。理解这四条线，绝大多数公式都能串起来。

1. 机器学习里最核心的总公式

几乎所有监督学习，都可以写成这个形式：

$$\min_{\theta} J(\theta) = \frac{1}{n} \sum_{i=1}^n L(f_{\theta}(x_i), y_i) + \lambda \Omega(\theta)$$

这里：

- x_i ：第 i 个输入样本
- y_i ：真实标签
- $f_{\theta}(x_i)$ ：模型预测
- $L(\cdot)$ ：损失函数，衡量“预测错了多少”
- $\Omega(\theta)$ ：正则项，防止过拟合
- λ ：控制正则强度
- θ ：模型参数

这一个式子几乎就是整个机器学习的骨架。

你看到的线性回归、逻辑回归、神经网络、SVM，本质上都只是：

1. 模型形式 f_{θ} 不同
2. 损失函数 L 不同
3. 正则项 Ω 不同

4. 优化方法不同

2. 线性模型：最基础的一类公式

2.1 线性回归

最经典公式：

$$\hat{y} = w^T x + b$$

也可以写成：

$$\hat{y} = \sum_{j=1}^d w_j x_j + b$$

含义：

- x ：特征向量
- w ：权重
- b ：偏置
- $\hat{y}$ ：预测值

它假设输出是输入特征的线性组合。

2.2 均方误差 MSE

线性回归常用损失函数：

$$L(\hat{y}, y) = (\hat{y} - y)^2$$

整个数据集上的目标函数：

$$J(w, b) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

也常写成带 $1/2$ 的形式，方便求导：

$$J(w, b) = \frac{1}{2n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

为什么用平方：

- 大误差惩罚更重
 - 可导、优化方便
 - 与高斯噪声假设一致
-

2.3 正规方程

在线性回归中，如果用矩阵表示：

$$\hat{y} = X w$$

最小二乘解为：

$$w = (X^T X)^{-1} X^T y$$

这叫**正规方程**。

它给出闭式解，不需要迭代，但要求 $X^T X$ 可逆，而且大规模时计算成本高。

2.4 Ridge 和 Lasso

Ridge (L2 正则)

$$J(w) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 + \lambda \|w\|_2^2$$

其中：

$$\|w\|_2^2 = \sum_j w_j^2$$

作用：

- 限制参数过大
- 提高稳定性
- 缓解多重共线性

- 不会把参数真正压成 0

Lasso (L1 正则)

$$J(w) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 + \lambda \|w\|_1$$

其中：

$$\|w\|_1 = \sum_j |w_j|$$

作用：

- 能做特征选择
- 让一部分参数直接变成 0

Elastic Net

$$J(w) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$$

它结合了 L1 和 L2。

3. 分类模型的核心公式

3.1 逻辑回归：Sigmoid

二分类里最经典的概率映射：

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

其中：

$$z = w^T x + b$$

所以逻辑回归输出：

$$P(y=1 | x) = \sigma(w^T x + b)$$

它把任意实数映射到 $(0, 1)$ ，因此适合表示概率。

3.2 逻辑回归的交叉熵损失

二分类常用损失：

$$L(y, \hat{p}) = -[y \log \hat{p} + (1 - y) \log (1 - \hat{p})]$$

整个目标函数：

$$J(w, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log (1 - \hat{p}_i)]$$

其中 $\hat{p}_i = P(y_i = 1 \mid x_i)$ 。

这个损失为什么重要：

- 它来自伯努利分布的极大似然
 - 预测越自信却越错，惩罚越大
 - 比 MSE 更适合分类概率建模
-

3.3 Softmax：多分类的核心公式

当类别有 K 个时：

$$P(y = k \mid x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

其中 z_k 是第 k 类的打分。

它的特点：

- 输出每个类别的概率
 - 所有类别概率之和为 1
-

3.4 多分类交叉熵

若真实标签用 one-hot 向量 y 表示，预测概率为 $\hat{y}$ ，则：

$$L(y, \hat{y}) = - \sum_{k=1}^K y_k \log \hat{y}_k$$

如果真实类别是 c ，可简写为：

$$L = - \log \hat{y}_c$$

这说明：

模型只要把真实类别的概率拉高，损失就会下降。

4. 概率视角：似然、极大似然、贝叶斯

机器学习很多公式其实都来自概率建模。

4.1 似然函数

给定参数 θ ，样本出现的概率：

$$L(\theta) = P(D \mid \theta)$$

其中 D 表示数据集。

若样本独立同分布：

$$L(\theta) = \prod_{i=1}^n P(y_i \mid x_i; \theta)$$

因为连乘不方便，通常取对数：

$$\log L(\theta) = \sum_{i=1}^n \log P(y_i \mid x_i; \theta)$$

4.2 极大似然估计 MLE

$$\theta^{\hat{}} = \arg \max_{\theta} P(D \mid \theta)$$

等价于：

$$\theta^{\hat{}} = \arg \max_{\theta} \log P(D \mid \theta)$$

再等价于最小化负对数似然：

$$\theta^i = \arg \min_{\theta} -\log P(D | \theta)$$

很多损失函数，本质上就是负对数似然。

例如：

- 高斯噪声 $\Rightarrow$ MSE
 - 伯努利分布 $\Rightarrow$ 二分类交叉熵
 - 多项分布 $\Rightarrow$ Softmax 交叉熵
-

4.3 贝叶斯公式

$$P(\theta | D) = \frac{P(D | \theta) P(\theta)}{P(D)}$$

含义：

- $P(\theta)$ ：先验
 - $P(D | \theta)$ ：似然
 - $P(\theta | D)$ ：后验
-

4.4 MAP 估计

最大后验估计：

$$\theta^i = \arg \max_{\theta} P(\theta | D)$$

等价于：

$$\theta^i = \arg \max_{\theta} [\log P(D | \theta) + \log P(\theta)]$$

这和“损失 + 正则”非常像。

也就是说：

- **极大似然**：只看数据
- **最大后验**：数据 + 先验约束

L2 正则可以看成高斯先验，L1 正则可以看成拉普拉斯先验。

5. 支持向量机 SVM 的核心公式

5.1 分类超平面

$$f(x) = w^T x + b$$

预测类别通常取符号：

$$\hat{y} = \text{sign}(w^T x + b)$$

5.2 间隔 Margin

对于样本 (x_i, y_i) ，其中 $y_i \in \{-1, +1\}$ ，函数间隔写作：

$$y_i(w^T x_i + b)$$

SVM 想最大化分类间隔，本质上让模型不仅分对，还要“分得远”。

5.3 硬间隔 SVM

$$\min_{w, b} \frac{1}{2} \|w\|^2$$

满足约束：

$$y_i(w^T x_i + b) \geq 1, \forall i$$

目标里最小化 $\|w\|^2$ ，其实等价于最大化间隔。

5.4 软间隔 SVM

加入松弛变量 ξ_i ：

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

约束：

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

这里 C 控制“间隔大”和“分类错误少”之间的平衡。

5.5 Hinge Loss

SVM 常写成损失最小化形式：

$$L(y, f(x)) = \max(0, 1 - yf(x))$$

整体目标：

$$J(w) = \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i f(x_i)) + \lambda \|w\|^2$$

6. 决策树与集成学习里的公式

6.1 熵 Entropy

分类不纯度的重要指标：

$$H(Y) = - \sum_{k=1}^K p_k \log p_k$$

- 类别越混乱，熵越大
 - 类别越纯，熵越小
-

6.2 信息增益

$$\text{Gain}(D, A) = H(D) - \sum_{v \in \text{Values}(A)} \frac{|D_v|}{|D|} H(D_v)$$

表示按特征 A 分裂后，不确定性减少了多少。

ID3 就是按信息增益选划分特征。

6.3 Gini 指数

CART 常用：

$$\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2$$

Gini 越小，节点越纯。

6.4 AdaBoost 权重更新

样本权重更新大意：

$$w_i^{(t+1)} = w_i^{(t)} \exp(-\alpha_t y_i h_t(x_i))$$

弱分类器权重：

$$\alpha_t = \frac{1}{2} \log \frac{1 - \epsilon_t}{\epsilon_t}$$

其中 ϵ_t 是第 t 个弱分类器错误率。

直观上：

- 分错的样本权重上升
 - 后续模型更关注难样本
-

6.5 梯度提升的核心思想

梯度提升不是直接拟合标签，而是拟合当前损失对预测的负梯度：

$$r_i^{(t)} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{t-1}}$$

然后：

$$F_t(x) = F_{t-1}(x) + \eta h_t(x)$$

其中：

- $h_t(x)$ ：当前弱学习器

- η : 学习率

这就是 GBDT / XGBoost / LightGBM 的核心思想。

7. 优化算法：参数是怎么学出来的

7.1 梯度下降

最基础公式：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$$

其中：

- η : 学习率
- $\nabla_{\theta} J(\theta)$: 梯度

含义：

沿着损失下降最快的反方向走一步。

7.2 随机梯度下降 SGD

对单个样本更新：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L_i(\theta)$$

mini-batch 版本：

$$\theta \leftarrow \theta - \eta \frac{1}{|B|} \sum_{i \in B} \nabla_{\theta} L_i(\theta)$$

相比全量梯度下降：

- 计算更快
 - 噪声更大
 - 更适合大数据和深度学习
-

7.3 Momentum

$$v_t = \beta v_{t-1} + (1 - \beta) \nabla_{\theta} J(\theta_t) \quad \theta_{t+1} = \theta_t - \eta v_t$$

作用：

- 减少震荡
 - 加快收敛
 - 类似“带惯性地滚下山”
-

7.4 Adam

一阶矩估计：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

二阶矩估计：

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

偏差修正：

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

参数更新：

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

Adam 的直觉：

- 利用梯度均值判断方向
 - 利用梯度方差调节步长
 - 不同参数自适应学习率
-

8. 神经网络的关键公式

8.1 单层神经元

$$z = w^T x + b \quad a = \phi(z)$$

其中 ϕ 是激活函数。

这就是“线性变换 + 非线性”。

8.2 常见激活函数

Sigmoid

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Tanh

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

ReLU

$$\text{ReLU}(z) = \max(0, z)$$

Leaky ReLU

$$\text{LeakyReLU}(z) = \begin{cases} z, & z > 0 \\ \alpha z, & z \leq 0 \end{cases}$$

ReLU 之所以流行，是因为：

- 计算简单
 - 缓解梯度消失
 - 训练深层网络更稳定
-

8.3 多层网络

第 l 层常写为：

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)} a^{(l)} = \phi(z^{(l)})$$

最后一层输出：

$$\hat{y} = f_{\theta}(x)$$

整个深度学习其实就是不断堆叠这种结构。

8.4 反向传播的核心：链式法则

若损失为 L ，则某层参数梯度：

$$\frac{\partial L}{\partial W^{(l)}} = \frac{\partial L}{\partial a^{(l)}} \cdot \frac{\partial a^{(l)}}{\partial z^{(l)}} \cdot \frac{\partial z^{(l)}}{\partial W^{(l)}}$$

本质就是把误差从后往前一层层传回去。

8.5 输出层常见搭配

- 回归：最后一层常直接线性输出
 - 二分类：最后一层用 Sigmoid + BCE
 - 多分类：最后一层用 Softmax + Cross Entropy
-

8.6 Dropout

训练时随机屏蔽神经元，可形式化为：

$$\tilde{h} = m \odot h, m_j \sim \text{Bernoulli}(p)$$

其中：

- m ：随机掩码
- $\odot$ ：逐元素乘法
- p ：保留概率

作用是减少神经元共适应，防止过拟合。

8.7 Batch Normalization

对一个 mini-batch:

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i, \sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

标准化:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

再进行缩放和平移:

$$y_i = \gamma \hat{x}_i + \beta$$

作用:

- 稳定训练
 - 允许更大学习率
 - 加快收敛
-

9. 序列模型公式

9.1 RNN

$$h_t = \phi(W_x x_t + W_h h_{t-1} + b) \quad y_t = W_y h_t + c$$

含义:

- 当前隐藏状态 h_t 依赖当前输入 x_t 和前一时刻状态 h_{t-1}

问题: 长序列里容易梯度消失或爆炸。

9.2 LSTM

遗忘门:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

输入门：

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

候选记忆：

$$\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$$

细胞状态更新：

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

输出门：

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$

隐藏状态：

$$h_t = o_t \odot \tanh(C_t)$$

这些门控公式的作用，就是让模型学会“该记什么、该忘什么”。

10. 注意力机制与 Transformer 公式

这是现代机器学习尤其大模型里的核心。

10.1 Scaled Dot-Product Attention

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

这里：

- Q : Query
- K : Key
- V : Value
- d_k : Key 维度

解释：

1. QK^T ：算相关性分数
 2. 除以 $\sqrt{d_k}$ ：防止数值过大
 3. softmax：转成权重
 4. 乘 V ：按权重聚合信息
-

10.2 Multi-Head Attention

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad \text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

多头的意义是：

不同头可以关注不同关系，比如语法、位置、语义依赖。

10.3 位置编码

经典 Transformer 中常用正弦位置编码：

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right) \quad PE(pos, 2i+1) = \cos\left(\frac{pos}{10000^{2i/d}}\right)$$

因为注意力本身不含顺序信息，所以要额外注入位置信息。

11. 无监督学习中的经典公式

11.1 K-means

目标函数：

$$J = \sum_{i=1}^n \sum_{k=1}^K r_{ik} \|x_i - \mu_k\|^2$$

其中：

- $r_{ik} = 1$ 表示样本 i 属于簇 k

- μ_k 是第 k 个簇中心

K-means 就是在最小化簇内平方误差。

簇中心更新：

$$\mu_k = \frac{1}{N_k} \sum_{i:r_{ik}=1} x_i$$

11.2 高斯混合模型 GMM

概率密度：

$$p(x) = \sum_{k=1}^K \pi_k N(x | \mu_k, \Sigma_k)$$

其中：

- π_k ：混合系数
- μ_k ：均值
- Σ_k ：协方差矩阵

它比 K-means 更强，因为它是“软聚类”。

11.3 EM 算法中的责任度

E 步：

$$\gamma(z_{ik}) = \frac{\pi_k N(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_i | \mu_j, \Sigma_j)}$$

表示样本 x_i 属于第 k 个高斯成分的概率。

11.4 PCA

数据中心化后，协方差矩阵：

$$\Sigma = \frac{1}{n} X^T X$$

然后求特征值分解：

$$\Sigma v = \lambda v$$

取最大特征值对应的特征向量作为主成分方向。

PCA 的目标可理解为：

- 最大化投影后方差
 - 最小化重构误差
-

11.5 PCA 的方差解释率

$$\text{Explained Variance Ratio}_k = \frac{\lambda_k}{\sum_j \lambda_j}$$

用来表示第 k 个主成了解释了多少信息。

12. 评价指标公式

12.1 分类指标

设：

- TP：真正例
- TN：真负例
- FP：假正例
- FN：假负例

Accuracy

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Precision

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1-score

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

什么时候看什么：

- 类别均衡：Accuracy 可参考
 - 关心误报：Precision 更重要
 - 关心漏报：Recall 更重要
 - 想平衡两者：F1
-

12.2 回归指标

MAE

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$$

MSE

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

RMSE

$$\text{RMSE} = \sqrt{\text{MSE}}$$

R^2

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

其中 $\bar{y}$ 是真实值均值。

含义：

- $R^2=1$ ：完美拟合
 - $R^2=0$ ：不比均值预测好
 - $R^2<0$ ：比直接猜均值还差
-

13. 泛化与偏差-方差公式

机器学习最终关心的不是训练集，而是泛化能力。

经典分解：

$$E\left[\left(\hat{f}(x) - f(x)\right)^2\right] = \text{Bias}^2 + \text{Variance} + \text{Noise}$$

解释：

- **Bias（偏差）**：模型太简单，学不够
- **Variance（方差）**：模型太敏感，过拟合
- **Noise（噪声）**：数据自身不可避免的误差

这就是为什么机器学习总在做平衡：

- 模型过简单：欠拟合
 - 模型过复杂：过拟合
-

14. 信息论相关公式

这些在损失函数和表示学习里很常见。

14.1 熵

$$H(P) = - \sum_x P(x) \log P(x)$$

14.2 交叉熵

$$H(P, Q) = - \sum_x P(x) \log Q(x)$$

14.3 KL 散度

$$D_{KL}(P \parallel Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

并且有关系：

$$H(P, Q) = H(P) + D_{KL}(P \parallel Q)$$

这说明：

最小化交叉熵，本质上是在让预测分布 Q 接近真实分布 P 。

15. 一些高级但常见的公式

15.1 对比学习 InfoNCE

$$L = - \log \exp \frac{\text{sim}(z_i, z_i^+) + \tau}{\text{sim}(z_i, z_i^+) + \text{sim}(z_i, z_i^-) + \tau}$$

其中：

- z_i ：当前样本表示
- z_i^+ ：正样本表示
- sim ：相似度函数
- τ ：温度参数

作用：让正样本更近、负样本更远。

15.2 VAE 的 ELBO

$$L(\theta, \phi; x) = E_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \| p(z))$$

它包含两部分：

- 重构项：能否生成原样本
 - KL 项：潜变量分布是否接近先验
-

15.3 强化学习里的价值函数

状态价值函数：

$$V^\pi(s) = E_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s \right]$$

动作价值函数：

$$Q^\pi(s, a) = E_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a \right]$$

Bellman 方程：

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r|s, a) [r + \gamma V^\pi(s')]$$

虽然强化学习通常单列，但它也属于机器学习的重要分支。

16. 怎样把这些公式真正串起来

如果只记公式，很快会乱。更有效的方法是按下面这条链理解：

16.1 第一步：选模型

$$\hat{y} = f_\theta(x)$$

比如：

- 线性回归: $w^T x + b$
 - 神经网络: 多层非线性变换
 - SVM: 间隔最大化分类器
 - Transformer: 注意力结构
-

16.2 第二步: 选损失

$$L(\hat{y}, y)$$

比如:

- 回归: MSE / MAE
 - 二分类: BCE
 - 多分类: Cross Entropy
 - 排序、对比学习: 特殊损失
-

16.3 第三步: 加约束

$$+ \lambda \Omega(\theta)$$

比如:

- L1: 稀疏
 - L2: 平滑、稳定
 - Dropout: 结构正则
 - Early stopping: 训练过程正则
-

16.4 第四步: 优化

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$$

用 GD / SGD / Adam 等把损失最小化。

16.5 第五步：评估

分类看：

- Accuracy
- Precision / Recall
- F1
- AUC

回归看：

- MAE
 - MSE / RMSE
 - R^2
-

17. 最值得你优先掌握的公式

如果你现在在学机器学习，最先应该彻底吃透的是这 12 个：

1. 线性模型

$$\hat{y} = w^T x + b$$

2. 总体经验风险最小化

$$\min_{\theta} \frac{1}{n} \sum_i L(f_{\theta}(x_i), y_i) + \lambda \Omega(\theta)$$

3. MSE

$$\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2$$

4. Sigmoid

$$\frac{1}{1+e^{-z}}$$

5. Softmax

$$\frac{e^{z_k}}{\sum_j e^{z_j}}$$

6. 交叉熵

$$-\sum_k y_k \log \hat{y}_k$$

7. L1 / L2 正则

$$\|w\|_1, \|w\|_2^2$$

8. 梯度下降

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$$

9. 链式法则 / 反向传播

10. 熵 / 信息增益

$$H(Y) = -\sum_k p_k \log p_k$$

11. K-means 目标

$$\sum_{i,k} r_{ik} \|x_i - \mu_k\|^2$$

12. 注意力

$$\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

把这几个搞明白，机器学习的大门基本就开了。

18. 一句话总结

机器学习里的公式，归根到底就是四类：

- **表示公式**：模型怎么从输入得到输出
- **概率公式**：模型如何解释数据生成过程
- **损失公式**：模型错了多少
- **优化公式**：参数如何更新

所以不要把它们看成零散知识点，而要看成一条链：

数据 → 模型 → 损失 → 梯度 → 更新 → 评估

这才是机器学习公式体系的核心逻辑。

如果你愿意，我下一条可以继续给你整理成一份更适合背诵的《机器学习公式速查表》，或者按“线性回归→逻辑回归→神经网络”顺序逐个推导。